



INSTITUTO POLITÉCNICO
NACIONAL
ESCUELA SUPERIOR DE CÓMPUTO



Ingeniería en Inteligencia Artificial

Reconocimiento de voz

Práctica 1: Representación del habla

Profesor:

Enrique Alfonso Carmona García

Alumno:

Velázquez Arrieta Eduardo Uriel

Fecha de entrega: 25 de septiembre de 2026

Índice

1. Introducción	2
2. Desarrollo	3
2.1. Dataset	3
2.2. Obtención de los coeficientes MFCC de manera manual	3
2.3. Obtención de los coeficientes MFCC con librosa	4
2.4. Comparación del primer audio (Audio 1: «Casa»)	5
2.4.1. Análisis de resultados y diferencias observadas	5
2.5. Comparación del segundo audio (Audio 2: «La casa es grande»)	6
2.5.1. Análisis de resultados y diferencias observadas	6
3. Conclusiones	7

Índice de figuras

1. MFCC Manual - Audio 1 (13 coeficientes).	5
2. MFCC Librosa - Audio 1 (20 coeficientes).	5
3. Comparación de coeficientes MFCC para el Audio 1.	5
4. MFCC Manual - Audio 2 (13 coeficientes).	6
5. MFCC Librosa - Audio 2 (20 coeficientes).	6
6. Comparación de coeficientes MFCC para el Audio 2.	6

1. Introducción

El procesamiento y reconocimiento automático del habla requiere transformar la señal acústica continua unidimensional en una representación compacta y representativa que capture las características fonéticas esenciales del tracto vocal humano, descartando variaciones irrelevantes como el ruido de fondo o peculiaridades del canal de transmisión. Entre las técnicas más consolidadas en este ámbito destacan los Coeficientes Cepstrales en las Frecuencias de Mel (*Mel-Frequency Cepstral Coefficients*, MFCC), los cuales modelan la percepción auditiva no lineal del oído humano mediante un banco de filtros espaciados triangularmente en la escala Mel y una descorrelación espectral mediante la Transformada de Coseno Discreta (DCT).

El objetivo principal de esta práctica es implementar y contrastar rigurosamente dos enfoques metodológicos para la extracción de coeficientes MFCC a partir de una misma señal de voz:

1. **Implementación manual paso a paso:** Diseñar y computar la cadena completa de procesamiento digital de señales sin recurrir a funciones de alto nivel preconstruidas para MFCC, abarcando las etapas de preénfasis, segmentación en tramas (*framing*), ventaneo temporal (Hamming), cálculo del espectro de potencia mediante la Transformada Rápida de Fourier (FFT), integración a través de un banco de filtros Mel, compresión logarítmica y la aplicación final de la DCT-II.
2. **Implementación estándar mediante biblioteca:** Extraer las características acústicas empleando la función nativa `librosa.feature.mfcc()` bajo sus configuraciones predeterminadas.

Para el desarrollo experimental se emplea el lenguaje de programación **Python**, apoyado en bibliotecas científicas fundamentales como **NumPy** y **SciPy** para la formulación vectorial y transformadas matemáticas de la implementación manual, **Matplotlib** para la generación y renderizado comparativo de espectrogramas y matrices cepstrales, y la librería especializada **Librosa** junto con **SoundFile** para la decodificación, manipulación acústica y cómputo de referencia. Asimismo, se integrará un conjunto de datos propio consistente en grabaciones de voz estructuradas a nivel de palabra aislada («*Casa*») y habla continua («*La casa es grande*»).

Como resultado de esta práctica, se espera obtener una reconstrucción visual fidedigna de las matrices de coeficientes cepstrales para ambas señales analizadas, así como cuantificar y justificar analíticamente las posibles discrepancias numéricas y dimensionales observadas entre ambos métodos. Dichas variaciones permitirán discutir en profundidad la influencia de hiperparámetros críticos del procesamiento en tiempo-frecuencia, tales como el tipo de relleno (*padding*), la normalización de área en los filtros Mel, las convenciones en el cálculo de la DCT ortogonal y el solapamiento de las ventanas temporales.

2. Desarrollo

2.1. Dataset

Para la experimentación se conformó un conjunto de datos acústicos compuesto por dos grabaciones de voz en formato digital (.mp3), registradas en un entorno controlado:

- **Audio 1:** Emisión a nivel de palabra aislada correspondiente a la frase «*Casa*», con una duración aproximada de 1.95 s.
- **Audio 2:** Emisión de habla continua correspondiente a la frase «*La casa es grande*», con una duración aproximada de 1.85 s.

Ambos archivos fueron leídos preservando su frecuencia de muestreo nativa (`sr=None`) mediante la función `librosa.load`, la cual normaliza de manera predeterminada la amplitud de la señal al intervalo de punto flotante $[-1.0, 1.0]$.

2.2. Obtención de los coeficientes MFCC de manera manual

El algoritmo implementado en la función `compute_mfcc` reproduce paso a paso la cadena clásica de procesamiento digital de señales acústicas:

1. **Preénfasis:** Se aplica un filtro FIR paso altas de primer orden expresado como:

$$y[n] = x[n] - \alpha x[n-1], \quad \text{con } \alpha = 0.97 \quad (1)$$

En el código se implementa vectorialmente con:

```
audio = np.append(audio[0], audio[1:] - 0.97 * audio[:-1])
```

Su objetivo es compensar la caída espectral natural de la voz humana (aproximadamente -6 dB por octava debido a la radiación labial) y amplificar las altas frecuencias.

2. **Segmentación en tramas (*Framing*) y Enventanado (*Windowing*):** Las señales de habla son cuasiestacionarias en intervalos de 20 a 30 ms. Se define una longitud de ventana de 25 ms (`win_length = int(round(0.025 * sample_rate))`) y un paso de avance (*hop*) de 10 ms (`hop_length = int(round(0.010 * sample_rate))`). La extracción eficiente de tramas sin copias redundantes de memoria se realiza con `np.lib.stride_tricks.as_strided`. Posteriormente, a cada trama se le aplica una ventana de Hamming simétrica:

$$w[n] = 0.54 - 0.46 \cos\left(\frac{2\pi n}{N-1}\right) \quad (2)$$

implementada mediante `frames *= np.hamming(win_length)`, reduciendo así las discontinuidades en los bordes y el fenómeno de fuga espectral (*spectral leakage*).

3. **Transformada Rápida de Fourier (FFT) y Espectro de Potencia:** Se calcula la Transformada Discreta de Fourier para señales reales con longitud $N_{\text{FFT}} = 512$ (`np.fft.rfft(frames, n=fft_length)`). A partir de la magnitud compleja, se estima el espectro de potencia normalizado:

$$P(k) = \frac{1}{N_{\text{FFT}}} |X(k)|^2 \quad (3)$$

reflejado en el código como `power_spectrum = (1.0 / fft_length) * (mag_frames ** 2)`.

4. **Banco de Filtros Mel:** Se simula la percepción frecuencial no lineal coclear mediante $M = 40$ filtros triangulares solapados linealmente espaciados en la escala Mel:

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right) \iff f = 700 (10^{m/2595} - 1) \quad (4)$$

Los centros de corte se mapean a los índices de frecuencia (*bins*) de la FFT, generando la matriz `fb` de dimensiones (40, 257).

5. **Energía de Filtro y Compresión Logarítmica:** Se proyecta el espectro de potencia sobre el banco Mel mediante un producto punto (`np.dot(power_spectrum, fb.T)`). Para evitar indeterminaciones matemáticas por ceros o valores negativos, se acota inferiormente con el épsilon de máquina (`np.finfo(float).eps`) y se aplica el logaritmo natural:

$$S_{\log}[m] = \ln(S[m]) \quad (5)$$

6. **Transformada de Coseno Discreta (DCT):** Se aplica la DCT Tipo II ortonormalizada (`norm='ortho'`) sobre el eje frecuencial logarítmico para descorrelacionar las componentes energéticas, seleccionando los primeros 13 coeficientes (`num_ceps=13`):

$$c[n] = \sum_{m=0}^{M-1} S_{\log}[m] \cos \left[\frac{\pi n}{M} \left(m + \frac{1}{2} \right) \right] \quad (6)$$

7. **Filtrado Cepstral (*Sinusoidal Lifting*):** Para atenuar la susceptibilidad al ruido en coeficientes superiores y balancear la escala dinámica, se aplica una ventana sinusoidal de realce con factor $L = 22$:

$$w_c[n] = 1 + \frac{L}{2} \sin \left(\frac{\pi n}{L} \right) \quad (7)$$

2.3. Obtención de los coeficientes MFCC con librosa

En la implementación estándar se utilizó la función de alto nivel `librosa.feature.mfcc(y=y, sr=sr, n_mfcc=20)`. Las características internas predeterminadas de Librosa conllevan diferencias de diseño fundamentales:

- **Transformada de Tiempo Corto (STFT):** Librosa no aplica preénfasis por defecto. Utiliza una ventana Hann centrada con relleno reflectivo (*centered padding*), con $n_{\text{fft}} = 2048$ y $\text{hop_length} = 512$ muestras.

- **Banco Mel y Escala:** Emplea de manera nativa la formulación Mel de Slaney (con espaciado lineal por debajo de 1 kHz y logarítmico por encima) y aplica normalización de área unitaria en cada triángulo (*area normalization*).
- **Compresión en Decibelios:** Convierte la potencia acumulada a decibelios en referencia al valor pico (`power_to_db`) en lugar de usar un simple logaritmo neperiano natural.
- **Dimensionalidad:** Por defecto calcula 20 coeficientes cepstrales y no aplica *liftering* sinusoidal.

2.4. Comparación del primer audio (Audio 1: «Casa»)

En la Figura 3 se muestra el contraste entre ambas representaciones para el Audio 1.



Figura 1: MFCC Manual - Audio 1 (13 coeficientes).




Figura 2: MFCC Librosa - Audio 1 (20 coeficientes).

Figura 3: Comparación de coeficientes MFCC para el Audio 1.

2.4.1. Análisis de resultados y diferencias observadas

- **Estructura Temporal:** En la implementación manual se aprecian claramente dos etapas: un intervalo de silencio inicial de 0 a 0.5s caracterizado por coeficientes base fuertemente negativos (≈ -125), seguido de la actividad acústica de la palabra «Casa» a partir de $t = 0.52$ s. En Librosa, el silencio inicial se sitúa en magnitudes en torno a -500 dB y la zona fonética eleva su energía por encima de $+200$ dB.
- **Resolución y Contraste Cepstral:** La versión manual ofrece una discriminación visual más detallada en los coeficientes intermedios y superiores (órdenes 2 a 12), producto del *liftering* sinusoidal que balancea las amplitudes relativas. Por el contrario, en Librosa la escala está dominada casi en su totalidad por el coeficiente de orden cero (c_0), el cual encapsula la energía logarítmica total de la trama y comprime la variación visual de los coeficientes de orden mayor.
- **Tiempos de Ejecución:** La ejecución manual para este audio tomó aproximadamente 0.308 s, mientras que Librosa requirió 1.171 s. Esta diferencia inicial responde al tiempo de carga e importación diferida de módulos y caché de filtros que efectúa Librosa en su primera invocación.

2.5. Comparación del segundo audio (Audio 2: «La casa es grande»)

La Figura 6 expone los coeficientes MFCC correspondientes a la frase en habla continua.




Figura 4: MFCC Manual - Audio 2 (13 coeficientes).




Figura 5: MFCC Librosa - Audio 2 (20 coeficientes).

Figura 6: Comparación de coeficientes MFCC para el Audio 2.

2.5.1. Análisis de resultados y diferencias observadas

- **Articulación Continua:** En el Audio 2 la actividad fonética se extiende a lo largo de toda la ventana temporal (0 a 1.85 s). En la matriz manual se diferencian con nitidez los formantes y transiciones consonántico-vocálicas asociadas a las sílabas constitutivas de la frase.
- **Discrepancia en Magnitudes y Rango Dinámico:** En la gráfica de Librosa la barra de color muestra un rango dinámico extremo (de -400 dB a $+250$ dB), lo cual satura visualmente los coeficientes superiores dejándolos con un tinte homogéneo y tenue. En el cálculo manual, el rango oscila entre -100 y $+70$, permitiendo apreciar el contorno de la envolvente espectral en todos los órdenes.
- **Tiempos de Cómputo en Régimen Estable:** Una vez inicializados los módulos internos en la memoria del intérprete, el cálculo de Librosa para el segundo audio descendió a 0.049 s, mientras que la versión manual optimizada con `np.lib.stride_tricks` y multiplicación matricial requirió únicamente 0.024 s, demostrando una alta eficiencia computacional al evitar la sobrecarga de generalización que maneja la librería.

3. Conclusiones

A través de la presente práctica se implementó y validó exitosamente la cadena matemática para la extracción de coeficientes MFCC, contrastando un modelo manual frente a la biblioteca especializada Librosa. Se concluye que:

- **Causas de variación espectral:** Las discrepancias visuales y cuantitativas entre ambos métodos obedecen a decisiones de preprocesamiento y diseño espectral:
 1. *Preénfasis:* La implementación manual incorpora un filtro FIR ($\alpha = 0.97$) que resalta componentes de alta frecuencia antes del ventaneo; Librosa omite esta etapa por defecto.
 2. *Fórmula Mel y Banco de Filtros:* La implementación manual emplea la fórmula estándar de O'Shaughnessy ($2595 \log_{10}$) con triángulos sin normalizar en área, mientras que Librosa implementa por defecto el banco de Slaney (`htk=False`, `norm='slaney'`), escalando cada filtro por su ancho de banda efectivo.
 3. *Compresión Dinámica:* El uso de `power_to_db` en Librosa frente al simple logaritmo neperiano (`np.log`) en el desarrollo manual genera escalas de amplitud dispares.
 4. *Liftering:* La inclusión del filtro sinusoidal en la versión manual equilibra las amplitudes relativas de los coeficientes c_1 a c_{12} , contrarrestando el dominio abrumador del coeficiente de energía c_0 , efecto ausente en la salida estándar de Librosa.
- **Eficiencia Computacional:** El cómputo manual vectorizado evidenció un rendimiento sumamente competitivo (0.024s frente a 0.049s en régimen estable), confirmando que una implementación compacta en NumPy/SciPy sin dependencias de alto nivel resulta viable y eficiente para sistemas de reconocimiento de patrones y habla embebidos o en tiempo real.

Referencias

- [1] B. McFee, C. Raffel, D. Liang, D. P. W. Ellis, M. McVicar, E. Battenberg y O. Nieto, “librosa: Audio and Music Signal Analysis in Python,” en *Proceedings of the 14th Python in Science Conference (SciPy 2015)*, Austin, TX, USA, 2015, pp. 18–25. doi: 10.25080/Majora-7b98e3ed-003.
- [2] S. Davis y P. Mermelstein, “Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 28, no. 4, pp. 357–366, ago. 1980. doi: 10.1109/TASSP.1980.1163420.
- [3] L. Rabiner y B. H. Juang, *Fundamentals of Speech Recognition*. Englewood Cliffs, NJ, USA: Prentice Hall, 1993.
- [4] X. Huang, A. Acero y H.-W. Hon, *Spoken Language Processing: A Guide to Theory, Algorithm, and System Development*. Upper Saddle River, NJ, USA: Prentice Hall PTR, 2001.